

Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Análisis de Datos
Tecnologías de la información.

Aprendizaje Supervisado, No Supervisado y Combinado

Por: Martínez Velarde Jesús Santiago 219439844

Introducción.

En la presente investigación se hace un análisis sobre el aprendizaje supervisado, el no supervisado y el mixto, como referencia de esta investigación se consultaron dos artículos científicos de la librería digital IEEE *Instituto de Ingenieros Eléctricos y Electrónicos*. Se analizan dos casos en particular haciendo énfasis en las ventajas y similitudes de los tipos de aprendizaje, cuando es necesario aplicarlos, es importante mencionar que ambos artículos presentan investigaciones avanzadas en la inteligencia artificial enfocándose en cómo los modelos pueden aprender de manera eficiente a partir de datos que tienen pocas o ninguna etiqueta manual, que se refiere que a las situaciones en las que el humano tiene que revisar la información cruda antes de que el modelo se le sea asignado una respuesta explícita.

Artículos Seleccionados.

1. Mix2Vec: Unsupervised Mixed Data Representation.

Introducción: Este artículo aborda la complejidad de trabajar con los datos del mundo real “heterogéneos” porque son dispersos, mezclan números con categorías. El etiquetar grandes volúmenes de datos es costoso en ciertos sectores y además los métodos tradicionales suelen fallar al intentar integrar diferentes tipos de atributos en un solo modelo, como solución los autores proponen un representador *Mix2Vec* que transforma datos humanos en un formato numérico que es entendible por el modelo.

Análisis y revisión.

Este artículo propone como alternativa a la necesidad de etiquetación de datos por humanos, es un modelo de representación que actúa como puente entre el aprendizaje supervisado y el no supervisado. Su función principal es el aprendizaje no supervisado, creando vectores de datos que luego pueden ser utilizados con cualquier tarea, el *Mix2Vec* es un representador neuronal profundo no supervisado. Esto es posible siguiendo la estrategia en la cual trabaja el representador.

"We conducted the ablation study of the Mix2Vec learning objective. The overall objective of Mix2Vec consists of three mechanisms: random shuffle prediction (RSP), prior distribution matching (PDR), and structural information maximization (SIM). We thus test different combinations of these mechanisms and use '+' to represent their combination." (Zhu et al., 2020).

"Llevamos a cabo el estudio de ablación del objetivo de aprendizaje de Mix2Vec. El objetivo general de Mix2Vec consta de tres mecanismos: predicción de reordenamiento aleatorio (RSP), coincidencia de distribución a priori (PDR) y maximización de la información estructural (SIM). Por lo tanto, probamos diferentes combinaciones de estos mecanismos y utilizamos el símbolo '+' para representar su combinación."

Como tal la combinación de los diversos mecanismos ayuda a verificar la contribución de cada una, por ejemplo un mecanismo de los ya mencionados PDM Prior Distribution Matching, su función es obligar a los datos procesados a tomar una distribución estadística para tener más orden.

Desarrollo y propuesta.

El estudio propone el desarrollo de un sistema representador de datos llamado *Mix2Vec*, un representador neuronal profundo de aprendizaje no supervisado diseñado para transformar datos mixtos y complejos en representaciones vectoriales y reutilizables, su propósito central es resolver las limitaciones de los métodos actuales ante datos del mundo real que suelen ser heterogéneos y dispersos.

2. The Performance of Supervised Machine Learning Based Relay Selection in Cooperative NOMA.

Introducción: Este artículo se centra en el uso del aprendizaje supervisado, presentando un algoritmo de Máquinas Vectores de Soporte (SVM) que funciona para optimizar la selección de relés en redes cooperativas que utilizan la tecnología NOMA (Non-Orthogonal Multiple Acces) que es una técnica para que varios usuarios usen la misma frecuencia al mismo tiempo., su objetivo es maximizar el rendimiento del sistema eliminando la complejidad computacional de los métodos tradicionales.

Análisis y Revisión.

Las redes inalámbricas modernas seleccionan el mejor relé y optimizan la transmisión NOMA simultáneamente, lo que es un problema de alta complejidad matemática porque el método tradicional que se usa para hallar el máximo global (El máximo global es el punto más alto, en el caso de la inteligencia artificial es el punto de configuración más eficiente) requiere todas las combinaciones posibles, lo cual demanda mucha energía y tiempo de procesamiento. El mismo autor propone que el aprendizaje supervisado es la mejor opción para simplificar estos problemas de optimización.

Desarrollo y propuesta.

Se propone una técnica de SVM como si fuera un clasificador multiclase, donde cada relé disponible se considera a una clase distinta, este sistema se entrena fuera de línea usando un gran conjunto de datos etiquetados, donde ya se conoce cual es el mejor relé por la técnica anterior de buscar todas las combinaciones posibles. Por lo tanto una vez optimizado el clasificador puede predecir el mejor relé en tiempo real con una carga computacional mínima, lo que evita retrasos en la red, así mismo se establece un mecanismo de cambio, es decir que si las condiciones no son buenas para soportar el NOMa, el sistema cambia automáticamente al modo OMA que es el método estándar que se usa en las redes celulares como 3G y 4G.

Conclusiones.

Siguiendo las fuentes consultadas, es un hecho que se revela un panorama integral sobre la inteligencia artificial que aborda la falta de datos no etiquetados en diversos campos técnicos, desde una perspectiva más sencilla, se le entrena a la IA como distinguir datos sin la necesidad de estar etiquetados, lo que ahorra un paso extra técnico que es supervisado por los humanos, el fin del aprendizaje no supervisado es que sea aun mas automatico cualquier proceso.

Las técnicas avanzadas de IA es la solución más eficaz para enfrentar el alto costo de etiquetado de datos y la complejidad de técnicas en entornos y datos reales.

El aprendizaje Semi-supervisado es la mejor alternativa, ya que no es viable ni ético tomar decisiones basadas en los resultados de la IA, generalmente el enfoque del aprendizaje supervisado es superior en rendimiento preciso, y el no supervisado ofrece una mayor capacidad de robustez al aprender de la estructura de los datos.

Bibliografía.

Alkhawatrah, M. (2023). The performance of supervised machine learning based relay selection in cooperative NOMA. IEEE Access, 11, 2486-2497.
<https://doi.org/10.1109/ACCESS.2022.3233443>

Couturier, A., & Almasan, A.-D. (2021). Semi-supervised domain adaptation via adversarial training. Thales UK.

Iswanto, B. H. (2005). Regularization of unlabeled data for learning of classifiers based on mixture models. Department of Physics, Jakarta State University.

Liu, X., Long, F., Huang, K., & Ling, Q. (2021). Enhanced unsupervised data augmentation for emergency events detection and classification. En 2021 33rd Chinese Control and Decision Conference (CCDC) (pp. 2367-2371). IEEE.

Zhu, C., Zhang, Q., Cao, L., & Abrahamyan, A. (2020). Mix2Vec: Unsupervised mixed data representation. University of Technology Sydney & Commonwealth Bank of Australia.